נספחים – ניתוחים וגרפים משלימים לניסויי הפרויקט

במהלך פיתוח הפרויקט ובחינת המסווגים הופקו גרפים נוספים, המופיעים בקוד הפרויקט ובפלטי ההרצות. מסמך נספחים זה מרכז את הגרפים ומספק הסבר על מטרתם ועל המידע שניתן להפיק מהם.

בדוח הפרויקט המרכזי בחרנו להתמקד בגרפים המציגים את הניסויים והתוצאות העיקריות, כדי לשמור על הצגה ממוקדת וברורה של הממצאים והמסקנות. הגרפים הנוספים, לעומת זאת, נועדו להעמיק את ניתוח הנתונים, לבחון את התנהגות המודלים ולהמחיש היבטים נוספים של תהליך הסיווג. עם זאת, חלקם מבוססים על מספר מצומצם של דוגמאות או נועדו בעיקר להמחשה, ולכן יש להתייחס אליהם כמידע משלים ולא כבסיס למסקנות חד־משמעיות.

הנספחים מחולקים לשני חלקים מרכזיים: מסווגי למידת מכונה ומודלי CNN. הגרפים הנוספים בשני מודלי ה־CNN הופקו באמצעות קוד דומה, שכן המודל המולטי־מודאלי פותח כהרחבה של המודל האקוסטי, תוך שמירה על תהליכי עיבוד וניתוח משותפים. לכן, כדי למנוע כפילות, ההסברים לגרפים אלו מוצגים במשותף. כל ההסברים מתייחסים לתוצאות כפי שהתקבלו ונשמרו בפלטי ההרצות המקוריות ב־Kaggle.

גרפים משלימים של מסווגי למידת מכונה

1. מטריצות בלבול נוספות (Confusion Matrices)

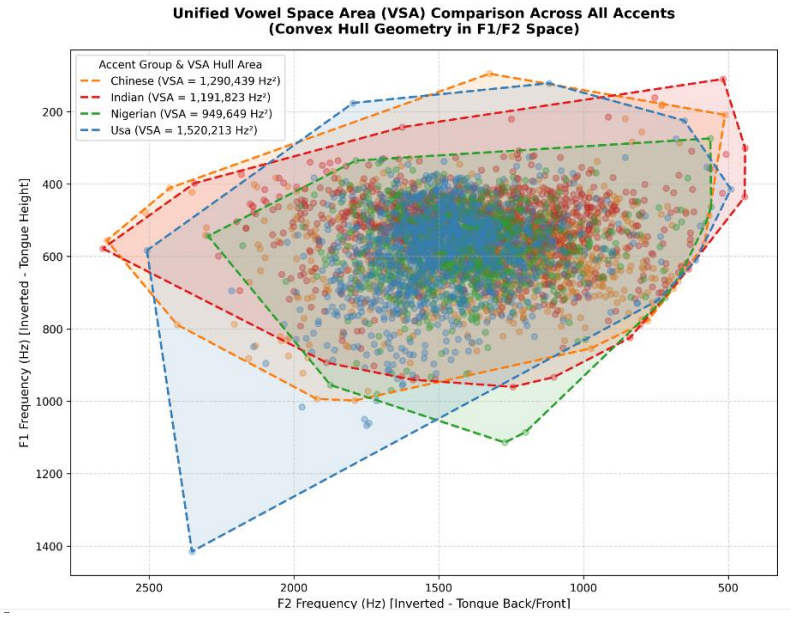
במסגרת הניסויים הופקו מטריצות בלבול עבור המסווגים השונים, במטרה לבחון את ביצועי הסיווג של כל מודל ברמת המבטא הבודד. המטריצות מאפשרות לזהות אילו מבטאים סווגו בהצלחה ואילו זוגות מבטאים התקשו המסווגים להבחין ביניהם.

בדוח המרכזי הוצגה מטריצת הבלבול של XGBoost, בעוד שהמטריצות הנוספות מאפשרות להרחיב את ההשוואה גם למסווגים האחרים.

2. גרפי היפר פרמטרים

במסגרת הניסויים הופקו גרפים המציגים את השפעת כוונון ההיפר־פרמטרים על ביצועי המסווגים השונים.
בדוח הפרויקט בחרנו להתמקד בתוצאות של XGBoost מכיוון שמסווג זה הציג את השיפור המשמעותי ביותר בעקבות הכוונון, בעוד שביתר המסווגים נצפה שיפור מתון או זניח. בנוסף, XGBoost השיג את אחוז הדיוק הגבוה ביותר מבין המסווגים שנבחנו.

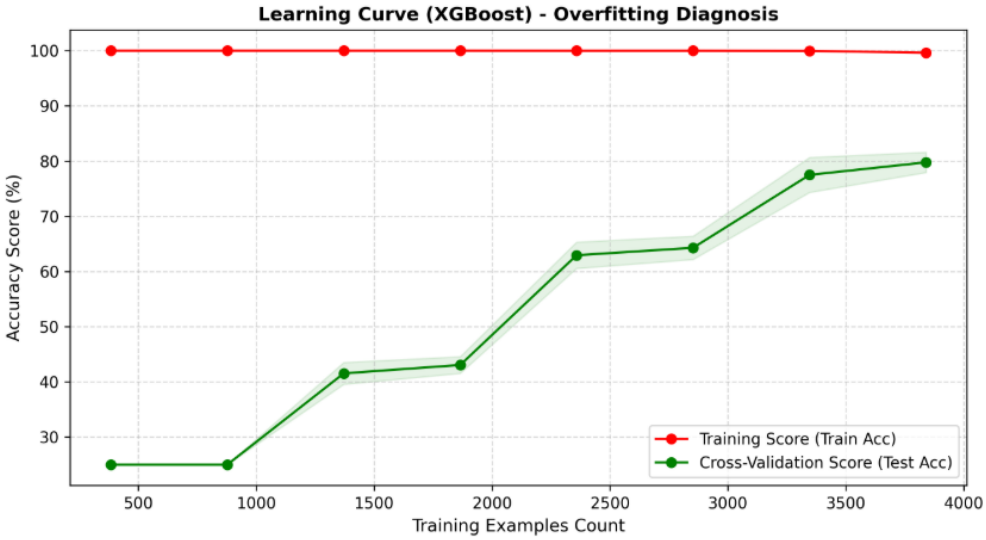
3. גרף מרחב התנועות הלשוניות (VSA – Vowel Space Area)



הגרף משווה את מרחב התנועות (VSA) של ארבע קבוצות המבטא, שעליו הורחב בפרק הפיצ׳רים. הציר האנכי מייצג את F1 הקשור לגובה הלשון, והציר האופקי מייצג את F2, הקשור למיקום הלשון קדימה ואחורה. בגרף מוצג השטח המכסה את פיזור הפורמנטים של כל מבטא.

מהגרף ניתן לראות כי המבטא האמריקאי מציג את מרחב התנועות הגדול ביותר, בעוד שהמרחב הניגרי מצומצם בכ־38% ומרוכז יותר. המבטאים ההודי והאמריקאי מציגים חפיפה משמעותית בין מרחבי התנועות שלהם. חפיפה זו ממחישה את הדמיון האקוסטי ביניהם ואת הקושי להבחין ביניהם על סמך הפורמנטים בלבד.

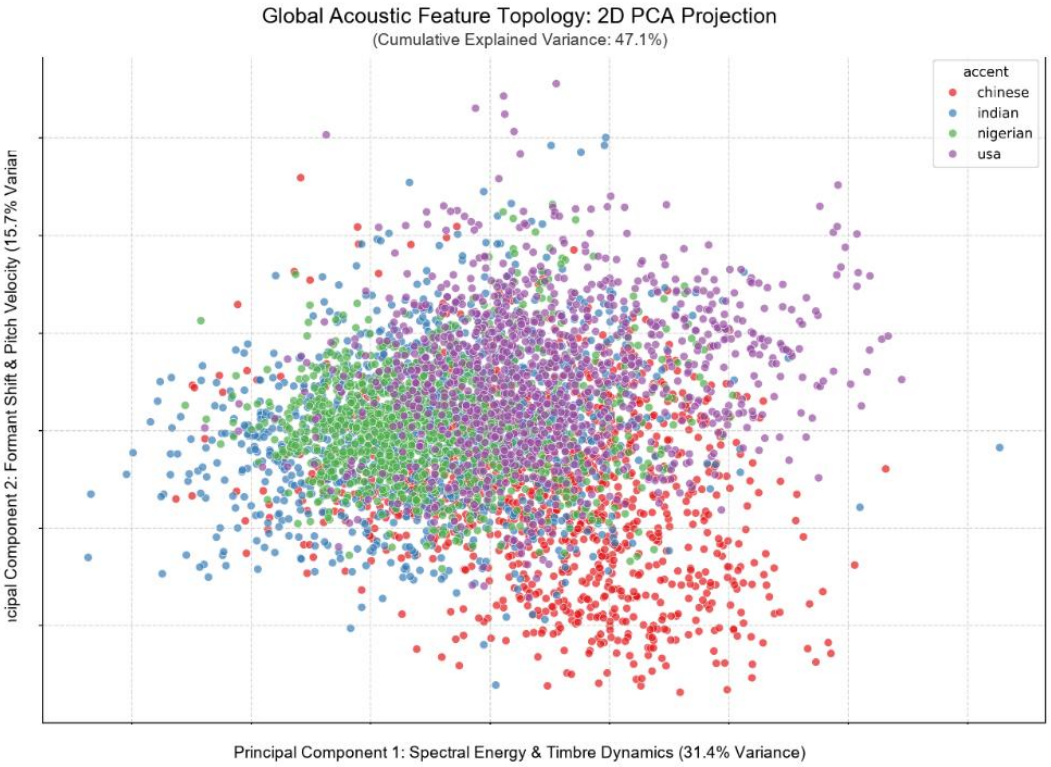
3. עקומות למידה (Learning Curves)



חלק זה מציג את עקומות הלמידה (Learning Curves) עבור מסווג ה XGBoost (הגרף למעלה) וה- Random Forest שפותחו בפרויקט. גרפים אלה הופקו ככלי בחינה משלים, במטרה לבחון את תהליך הלמידה של המודל ואת הפער בין אחוז הדיוק באימון לדיוק בטסט. בגרפים אלה, הקו האדום מייצג את אחוז הדיוק על נתוני האימון בעוד הקו הירוק מייצג את אחוז הדיוק על נתוני המבחן. הניתוח בוצע על גבי כלל הדגימות במאגר הנתונים, כאשר ציר ה-X מייצג את כמות דגימות האימון וציר ה-Y מייצג את אחוז הדיוק בסיווג ארבעת המבטאים .

מהגרפים ניכר כי עם הגדלת נתוני האימון, הדיוק בסט המבחן (הקו הירוק) עולה באופן רציף בהתאם להגדלת המאגר. מצידו השני, הקו האדום מציג דיוק גבוה בסט האימון שמאפיין מודלים מבוססי עצים בעלי יכולת למידה גבוהה . הפער שנוצר בין הקווים מציג את ההפרש בין ביצועי המודל על נתוני האימון לבין ביצועיו על נתוני המבחן, אך המגמה העולה והמתמשכת של הקו הירוק מוכיחה כי המודל לומד היטב את הדפוסים האקוסטיים והפונטיים ומפגין יכולת הכללה טובה בסיווג ארבעת המבטאים. מגמה זו מראה כי כדי להמשיך ולהשתפר בצמצום הפער יש להגדיל עוד יותר את המאגר. הגדלת המאגר לא התאפשרה במסגרת הפרויקט בשל האתגרים הכרוכים בשמירה על איכות הנתונים ובעמידה בדרישות שקבענו לגיוון המאגר.

4. המחשת הפיצ׳רים באמצעות PCA



הגרף מציג את פיזור הדוגמאות של ארבע קבוצות המבטא באמצעות ניתוח PCA, המאפשר לצמצם את הפיצ׳רים האקוסטיים המובילים, שנבחרו לפי ANOVA F-Score, לשני צירים מרכזיים: PC1 ו־ PC2, צירים אלו מייצגים שילובים של הפיצ׳רים ומסבירים יחד 47.1% מהשונות בנתונים. כל נקודה בגרף מייצגת דגימת דיבור, והצבע שלה מציין את המבטא.

מהגרף ניתן לראות כי המבטאים הסיני והניגרי מציגים הפרדה ברורה יותר, בעוד שבין המבטאים האמריקאי וההודי קיימת חפיפה משמעותית. ממצא זה תואם את התוצאות במטריצות הבלבול וממחיש את הקושי להבחין בין שני המבטאים על סמך הפיצ׳רים האקוסטיים. הגרף משלים את ניתוח UMAP שהוצג בדוח ומספק נקודת מבט נוספת על ההבדלים בין המבטאים.

חשוב לציין כי גרף זה רלוונטי לניסוי שבו מופעל סינון ל־30 הפיצ׳רים המובילים בלבד, ואינו מייצג את הניסויים שבהם נעשה שימוש בכלל הפיצ׳רים.

גרפים משלימים של מודלי ה- CNN

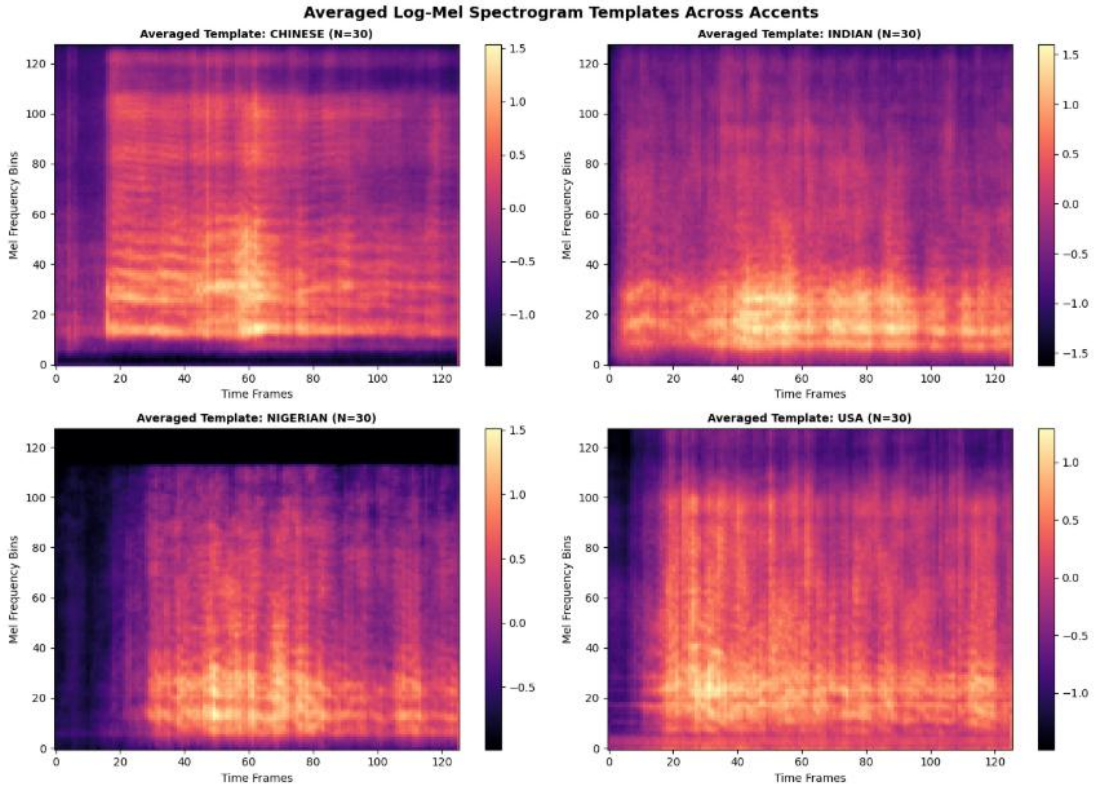
1. מטריצות בלבול – ערכים מוחלטים ומנורמלים

הקוד מפיק שתי מטריצות בלבול מסכמות, הראשונה מציגה את מספר הדוגמאות שסווגו לכל מבטא, והשנייה מציגה את אותן תוצאות באחוזים, ביחס למספר הדוגמאות בכל מבטא. שתי המטריצות מאפשרות לראות כמה דוגמאות סווגו נכון או שגוי, ולבחון את שיעורי ההצלחה ואת הבלבול בין המבטאים השונים.

2. מפות Grad-CAM של המודל האקוסטי

הגרף מציג מפות חום של Grad-CAM עבור מודל ה-CNN האקוסטי, ומדגיש אזורי זמן ותדר בספקטרוגרמה שהשפיעו על החלטות הסיווג. בפרויקט החלטנו להציג את מפות אלה עבור CNN דו ענפי בשל אחוז הדיוק הגבוה יותר בו.

3. ספקטרוגרמות ממוצעות לפי מבטא (Averaged Log-Mel Spectrogram Templates Across Accents)

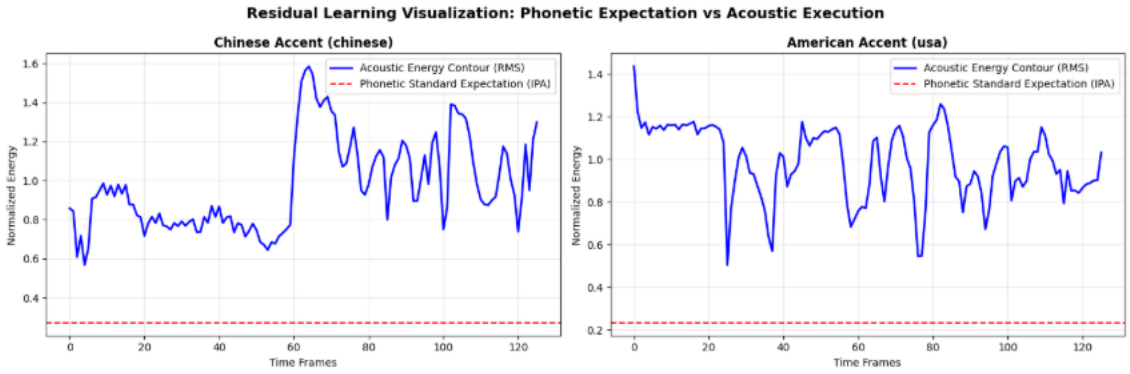


הגרף מציג ספקטרוגרמות Log-Mel ממוצעות עבור ארבע קבוצות המבטא, המבוססות על מדגם של 30 הקלטות מכל קבוצה. כל ספקטרוגרמה מתארת את התפלגות האנרגיה האקוסטית לאורך הזמן והתדר, כאשר צבעים בהירים מייצגים עוצמת אנרגיה גבוהה יותר. לצורך יצירת התבניות, ההקלטות הותאמו לאורך אחיד ולאחר מכן חושב ממוצע הערכים בכל נקודה בספקטרוגרמה.

מהגרף ניתן לראות כי מרבית האנרגיה מרוכזת בתדרים הנמוכים והבינוניים ,וכי קיימים הבדלים בין המבטאים. במבטאים הסיני והאמריקאי נראים שינויים חדים יותר בעוצמת האנרגיה לאורך הזמן, בעוד שבמבטאים ההודי והניגרי השינויים מתונים יותר והאנרגיה נשמרת באופן רציף לאורך מקטעי הדיבור. הבדלים אלו עשויים להעיד על שוני בקצב הדיבור ובאופן הגיית התנועות, וממחישים את המידע האקוסטי שמודלי ה־ CNN יכולים ללמוד מתוך הספקטרוגרמות.

הגרף מבוסס על מדגם של 30 הקלטות מכל מבטא ,ולכן אינו מייצג בהכרח את כלל מאפייני הדיבור של כל קבוצה .מסיבה זו הוא לא נכלל בדוח המרכזי ,אלא מוצג בנספחים כהמחשה חזותית של הבדלים אפשריים בין המבטאים.

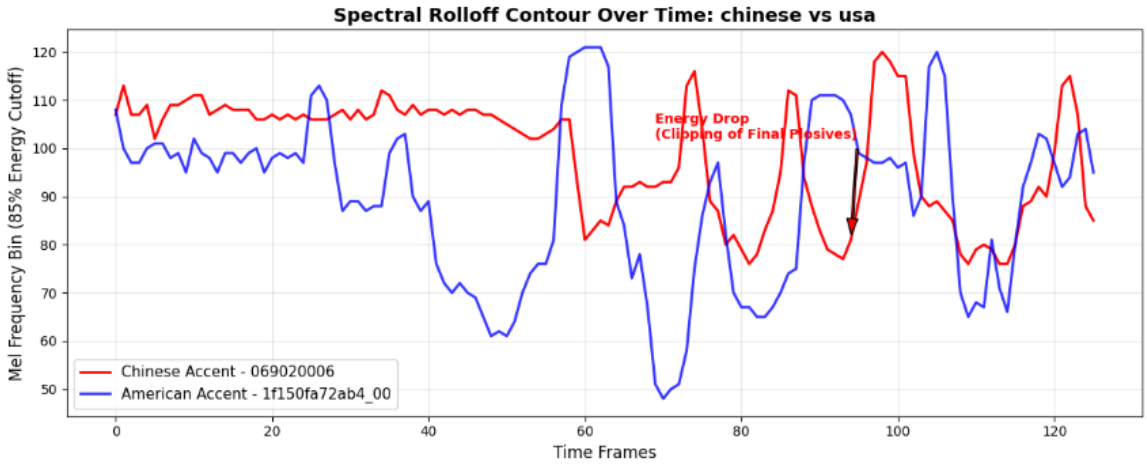
4. ניתוח דפוסי אנרגיה לאורך זמן (Residual Learning Visualization)



הגרף ממחיש כיצד מודל ה Dual-Branch CNN לומד את השארית (Residual), כלומר את הפער שבין הציפייה הפונטית מהטקסט לבין הביצוע האקוסטי בפועל ובכך הוא מסביר כיצד הוספת הענף הפונטי מסייעת בתיקון שגיאות אקוסטיות .הקו האדום המקווקו מציג את ממוצע הפיצ׳רים הפונטיים (IPA) של הטקסט, ומייצג קו בסיס תיאורטי אחיד המייצג את רמת האנרגיה הממוצעת שהיינו מצפים לקבל מתוך המילים עצמן, ללא קשר לאופן שבו הדובר ביטא אותן בפועל .לעומתו, הקו הכחול מציג את עוצמת האנרגיה האקוסטית שנמדדה בפועל לאורך זמן באמצעות ממוצע ריבועי (RMS Energy) של תדרי ה Mel-מתוך השמע, ומייצג את אופן ההגייה הממשי בשטח .

הפער הבולט בין קו הייחוס התיאורטי (האדום) לבין האנרגיה האקוסטית הממשית (הכחולה) ממחיש מדוע נדרשת למידה משולבת, בעוד שהמידע הפונטי שנגזר מהטקסט מספק ציפייה בסיסית בלבד, המודל לומד את ה – ״Residual״ כלומר את השארית או הסטייה מקו הייחוס שנוצרת בעקבות השינויים הדינמיים וההטעמות הייחודיות לכל מבטא .בגרפים המוצגים ניתן לראות כי המבטא הסיני מתאפיין בקטעי אנרגיה נמוכה ולאחריהם קפיצות חדות, בעוד המבטא האמריקאי מציג שינויים עוצמתיים ורצופים עם נפילות אנרגיה מהירות בין הברות .

5. התפלגות האנרגיה הספקטרלית לאורך זמן (Spectral Rolloff Contour)



גרף זה מציג את המדד האקוסטי Spectral Rolloff לאורך ציר הזמן עבור דגימות מייצגות מהמבטא הסיני והמבטא האמריקאי .מדד זה מציין את גבול התדר שבו מרוכזים 85% מאנרגיית האות בכל חלון זמן, ומספק אינדיקציה כמותית לשינויים בגוון הקול ובבהירות השמע ,שכן עליה בערך ה- Rolloff מעידה על נוכחות תדרים גבוהים וחדים (נקרא צליל 'בהיר'), בעוד ירידה מעידה על ריכוז אנרגיה בתדרים נמוכים ועמוקים.

הגרף ממחיש הבדלים ברורים בדינמיקה הספקטרלית בין המבטאים .כך למשל, ניתן להבחין בנפילת אנרגיה חדה במבטא הסיני, המייצגת דפוס של קיטוע או השמטה של עיצורים פוצצים בסופי מילים. שינויים דינמיים אלו בפיזור האנרגיה בתדרים הגבוהים לאורך זמן מספקים למודלי ה- CNN מאפיינים מפרידים שיכולים לסייע לזיהוי המבטא .