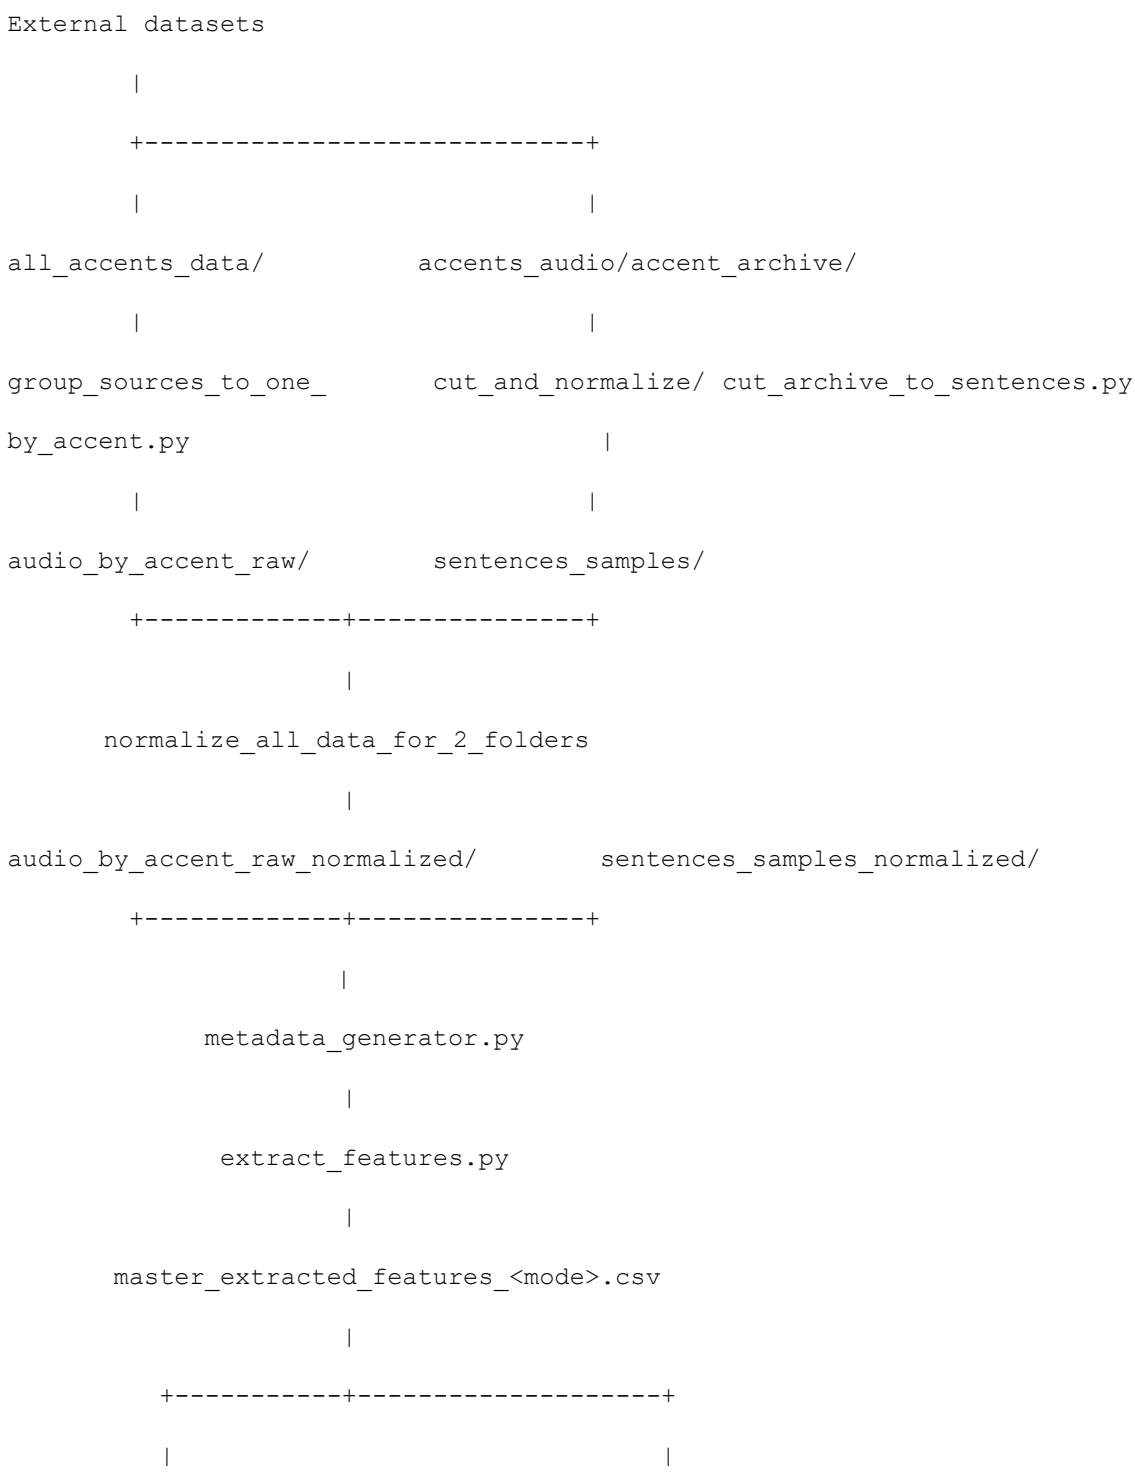
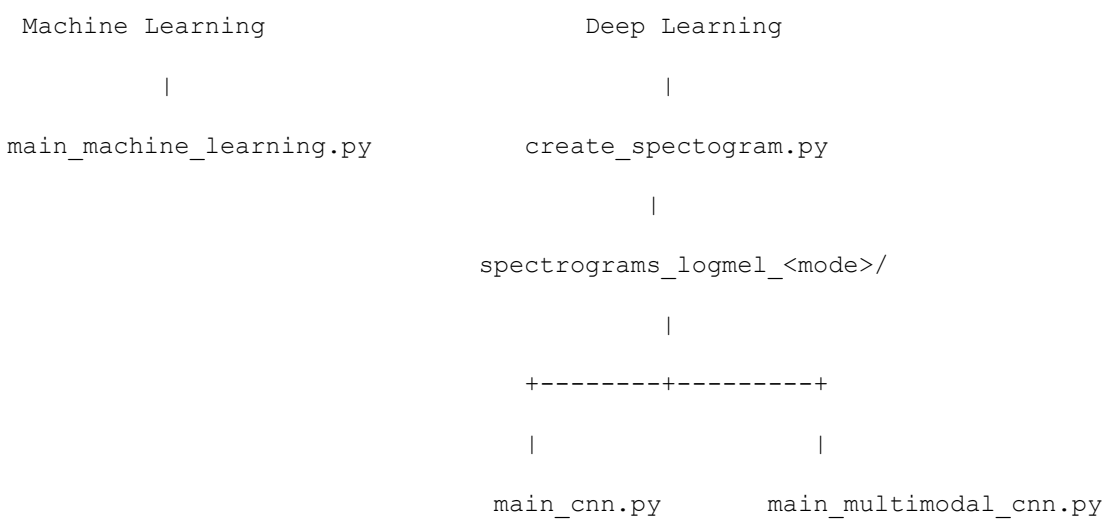
תיעוד חיצוני למתכנת

1. מבנה כללי

המערכת מתחילה ממאגרי אודיו ממספר מקורות. לאחר ארגון הנתונים, חיתוך ההקלטות נרמולן ויצירת metadata, מופעל שלב משותף של חילוץ פיצ'רים. לאחר מכן התהליך מתפצל למסלול Machine Learning ולמסלולי CNN.





2. מבנה קובצי האודיו

לאחר איחוד מקורות ה-Free Text בעזרת הקובץ group_sources_to_one_by_accent.py , קבצי האודיו מסודרים לפי מבטא:

```
audio_by_accent_raw/
├── chinese/
├── indian/
├── nigerian/
└── usa/
```

Speech Accent Archive נשמר בנפרד וגם הוא מסודר לפי מבטא:

```
accents_audio/
└── accent_archive/
    ├── chinese/
    ├── hindi/
    ├── nigerian/
    └── usa/
```

ההפרדה לפי מבטא נשמרת גם בשלבי העיבוד הבאים כדי לאפשר יצירת metadata ובקרה על הרכב הנתונים.

2.1 חיתוך מאגר speech accent archive

לתורך הרצה של קטעי אודיו ממאגר speech accent archive עם מאגר free_text חתכנו כל קטע אודיו לשישה משפטים . החיתוך מתבצע בעזרת הקובץ הבא שבתיקיית:

```
cut_and_normalize/cut_archive_to_sentences.py
```

התהליך נעזר בקבצים `audio_time_split.py` ו- `sentences_extractor.py` שמשתמשים בספריית Whisper כדי לחלק כל קטע אודיו לששת המשפטים המפורטים בדוח הפרויקט.
הפלט נשמר תחת תיקיית `sentences_samples/` ובתוך כל מבטא קיימת תיקייה נפרדת לכל משפט.

3. נרמול קבצי האודיו

לאחר יצירת שתי תיקיות האודיו המרוכזות מהסעיף הקודם , נעביר לכל תיקיית אודיו נרמול בעזרת הקוד normalize_all_data_for_2_folders שבתיקיית cut_and_normalize .

כעת נקבל את התיקייה `audio_by_accent_raw_normalized` עבור קבצי מאגר `free_text`
ותיקיית `sentences_samples_normalized` עבור מאגר speech accent archive .

4. מצבי הנתונים

המערכת תומכת בשלושה מצבים (מאגרים) :

```
archive_only

free_text

mixed
```

בתוך הקוד יש לבחור את מאגר הנתונים עליו רצים (free_text/mixed/archive_only) ,

המצב ריצה נבחר בשורה בה כתוב :

```
RUN_MODE = "free_text"
```

אותו mode צריך להישמר בין ה-metadata, קובץ הפיצ'רים, הספקטרוגרמות וקובץ ההרצה.

5. Metadata ופיצ'רים

metadata_generator.py יוצר את קובצי ה-metadata. הקובץ מפעיל את הפונקציה המתאימה מתוך K_fold.py בהתאם למצב הנתונים שנבחר באמצעות RUN_MODE.

הקובץ K_fold.py אחראי על יצירת מאגרי הנתונים ,אחידות שמות העמודות ,ניקוי נתיבי הקבצי ,ואחידות מזהי הדוברים.

extract_features.py מפעיל את חילוץ הפיצ'רים שבתיקיית features/ על מאגר המטא-דאטה המתאים למצב שנבחר ב -RUN_MODE . בסיומו הוא יוצר את אחד מקבצי הפיצ'רים הבאים:

```
master_extracted_features_archive_only.csv

master_extracted_features_free_text.csv

master_extracted_features_mixed.csv
```

זהו שלב משותף לפני הפיצול. מסלול Machine Learning משתמש בטבלת הפיצ'רים כקלט המרכזי, ו- Multimodal CNN משתמש בחלק מהפיצ'רים יחד עם הספקטרוגרמה.

6. יצירת קובצי הספקטוגרמה

create_spectogram.py יוצר את קובצי תיקיות הספקטוגרמה. הקובץ בונה לכל מאגר (שנבחר באמצעות RUN_MODE) את הספקטוגרמות של קבצי האודיו שנבחרו במטא-דאטה שלו . אופן יצירת הספקטרוגרמות בקוד מפורט בסעיף מבני הנתונים בפרויקט.

בסיום התהליך נוצרת תיקיות ספקטוגרמה בשם `spectograms_logmel_<mode>/` בהתאם למאגר בו בחרנו.

6. הרצה דרך pycharm

6.1 מסלול למידת מכונה

הקובץ:

```
main_ machine_learning.py
```

מנהל את ניסויי למידת המכונה. המסווגים נמצאים תחת:

```
classifiers/
```

הקלט המרכזי הוא קובץ:

```
master_extracted_features_<mode>.csv
```

הקוד מאפשר לבחור את מצב הנתונים, להפעיל Feature Selection, לקבוע את מס' הפיצ'רים לפיהם המסווגים יפעלו ולבחור את שיטת כוונון ההיפר-פרמטרים.

6.2 המודל האקוסטי

הקלט שלו הן הספקטרוגרמות הנוצרות באמצעות :

```
cut_and_normalize/create_spectogram.py
```

בתוך הקוד יש לבחור את מאגר הנתונים עליו רצים (free_text/mixed/archive_only) :

```
RUN_MODE = "free_text"
```

הספקטוגרמות של מאגר הנתונים נשמרות בתיקייה:

```
spectrograms_logmel_<mode>/
```

אחרי יצירתן ניתן להפעיל את המודל האקוסטי באמצעות הקובץ:

```
main_cnn.py
```

6.3 המודל המולטי-מודאלי

המודל המולטי-מודאלי מופעל באמצעות:

```
main_multimodal_cnn.py
```

הוא מקבל שני סוגי קלט: ספקטרוגרמת Log-Mel ופיצ'רים פונטיים מתוך קובץ הפיצ'רים.

6.4 ניסוי ההשוואה בין הספקטוגרמות על מאגר archive :

מטרתו להשוות בין ספקטרוגרמות מסוג Linear Mel ו־ Log-Mel. כל הקבצים הרלוונטים לקוד זה מצויים תחת תיקיית `archive_cnn_dataset/` . בקוד זה אין צורך לבחור מאגר נתונים אלא פשוט להריץ.

מריצים:

```
archive_cnn.py
```

7. הרצה דרך kaggle

7.1 מחברת למידת המכונה

המחברת בנויה ממספר חלקים עיקריים:

- בתחילת המחברת מוגדר מצב ההרצה, מאותרים קובצי הפיצ'רים ונבדקת תקינות הנתונים.
- לאחר מכן מתבצע preprocessing של הטבלה: הסרת עמודות שאינן פיצ'רים, טיפול בערכים חסרים ונרמול פיצ'רים.
- אם Feature Selection מופעל, הפיצ'רים מדורגים באמצעות ANOVA ונבחרים הפיצ'רים המובילים.
- האימון מתבצע ב- Nested Group 10-Fold Cross-Validation לפי דובר, ולאחריו נבדק שאין Speaker Leakage.
- בסיום מוצגים Accuracy, Macro F1, מטריצות בלבול וניתוחים של חשיבות ותרומת הפיצ'רים.

מחברת:

https://www.kaggle.com/code/alonlev001/main-for-machine-learning

7.2 מחברת המודל CNN האקוסטי

המחברת מחולקת לשלבים הבאים:

- הגדרת מצב ההרצה, בחירת GPU או CPU, איתור ה-metadata והספקטרוגרמות ובדיקת התאמה ביניהם.
- הגדרת Dataset, SpecAugment ומודל CNN בעל שלושה בלוקים קונבולוציוניים.
- אימון והערכה ב-5-Fold Group Cross-Validation לפי דובר, כולל Validation ושמירת המודל הטוב בכל Fold.
- בדיקה מפורשת שאין חפיפה של דוברים בין Train, Validation ו-Test.
- הפקת מדדי Accuracy ו-Macro F1, מטריצות בלבול וגרפים לניתוח המודל, כגון Grad-CAM וספקטרוגרמות ממוצעות .

מחברת:

https://www.kaggle.com/code/alonlev001/ai-accent-classifier-cnn

7.3 מחברת המודל CNN המולטי-מודאלי

המחברת דומה למסלול ה-CNN, אך מוסיפה זרוע פונטית:

- טעינת הספקטרוגרמה יחד עם וקטור פונטי הכולל חמישה פיצ'רים.
- הזרוע האקוסטית מעבדת את הספקטרוגרמה והזרוע הפונטית מעבדת את הווקטור.
- שני הייצוגים משולבים לפני הסיווג באמצעות מנגנון Gated Residual Fusion.
- האימון מתבצע ב-5-Fold Group Cross-Validation עם בדיקת Speaker Leakage ושמירת המודל הטוב.
- בסיום מופקים מדדי ביצוע, מטריצות בלבול וגרפי ניתוח. מחברת:

https://www.kaggle.com/code/alonlev001/ai-accent-classifier-multimodal-cnn

המחברת כוללות גם מנגנון קלט לקובץ אודיו חדש, הכולל תמלול, יצירת הווקטור הפונטי, יצירת הספקטרוגרמה וסיווג המבטא.

7.4 ניסוי ההשוואה בין הספקטוגרמות על מאגר archive

המחברת משווה בין ביצועי מודל CNNהמשתמש בספקטרוגרמת Linear Mel לבין מודל המשתמש בספקטרוגרמת Log-Mel:

- טעינת הקלטות ממאגר Archive ועיבודן לאורך אחיד של 45 שניות, בקצב דגימה של 16kHz.
- יצירת שתי ספקטרוגרמות מכל הקלטה: Linear Mel בסקאלה ליניארית ו־ Log-Mel בסקאלה לוגריתמית (dB). על כל אחת מהן מתבצע נרמול Z-Score בנפרד.
- חלוקת הנתונים לקבוצות אימון, אימות ובדיקה לפי מזהי דוברים, כדי למנוע Speaker Leakage .
- אימון שני מודלי CNN באותה ארכיטקטורה ובאותה חלוקת נתונים, למשך 30 אפוקים כאשר ההבדל ביניהם הוא סוג הספקטרוגרמה.
- בסיום מופקים גרפים המשווים את ה־ Accuracy ו ה־ Loss לאורך האימון, וכן השוואת הדיוק על קבוצת הבדיקה ומטריצות בלבול עבור שני המודלים.

מחברת:

https://www.kaggle.com/code/alonlev001/archive-cnn

7.5 מימוש מודלי ה-CNN

המודל האקוסטי מבוסס על שלושה בלוקים קונבולוציוניים, הכוללים 20, 40 ו־80 פילטרים בהתאמה. הבחירה בארכיטקטורה מצומצמת נועדה להתאים את מורכבות המודל לגודל מאגר הנתונים (כ־5,000 דגימות), ובכך להפחית את הסיכון ל־ Overfitting וללמידת רעשי רקע במקום מאפייני המבטא. בכל בלוק מתבצע MaxPooling בגודל 2×2, המצמצם בהדרגה את ממדי המידע תוך שמירה על דפוסים אקוסטיים חשובים לזיהוי המבטאים.

במודל המולטי־מודאלי משולבים גם מאפיינים פונטיים המבוססים על ספירת צלילי IPA . תחילה, המאפיינים הפונטיים מועברים דרך שכבה ליניארית המרחיבה אותם ל־80 תכונות, בהתאם לגודל הייצוג האקוסטי. לאחר מכן, השילוב מתבצע באמצעות מנגנון Residual Gate המשתמש בפונקציית Sigmoid לחישוב משקל בין 0 ל־1 עבור המידע הפונטי בכל דגימה. מנגנון זה מאפשר למודל להתאים את תרומת המידע הפונטי לכל דגימה ומפחית את הסיכון שהמודל יתעלם ממנו בשל הדומיננטיות של המידע האקוסטי. המידע הפונטי מוכפל במשקל שנקבע ומתווסף לייצוג האקוסטי, כך שהמודל שומר על המידע האקוסטי כבסיס ומשתמש במאפיינים הפונטיים כמידע משלים, שעשוי לסייע בהבחנה בין מבטאים דומים.

7.6 גרפים ותוצרים

ב-Kaggle חלק מהגרפים מוצגים ישירות בפלט המחברת וב-output. בהרצה מקומית ב-PyCharm הם נשמרים גם תחת:

```
graphs/
```

הוספת פיצ'ר חדש

כדי להוסיף פיצ'ר חדש יש לממש אותו תחת תיקיית features/, לחבר אותו ל-extract_features.py כך שיתחבר לקובץ הפיצ'רים .

הוספת מסווג חדש

מסווג Machine Learning חדש צריך להיכנס לתיקיית classifiers/ ולחברו ל-main_machine_learning.py. רצוי לשמור על אותו ממשק קלט ופלט של המסווגים הקיימים.

מבני נתונים בפרויקט

המערכת מעבירה בין שלבי העיבוד והמודלים ארבעה מבני נתונים עיקריים: קובץ מטא-דאטה, טבלת מאפיינים מרוכזת, טנזורי ספקטרוגרמה ווקטור ייצוג פונטי.

1. קובץ מטא-דאטה (`massive_metadata_<mode>.csv`)

טבלת ה-CSV המרכזית מאגדת את נתוני הבסיס של כל דגימת אודיו במאגר. היא נוצרת על ידי `metadata_generator.py` ו-`K_fold.py`, ובמאגר ה-Free Text כוללת 4,800 שורות ו-5 עמודות:

תיאור	עמודה
שם קובץ האודיו (למשל `WAV.069020006`)	`filename`
הנתיב המלא או היחסי לקובץ האודיו המנורמל במערכת הקבצים	`file_path`
מזהה ייחודי לדובר - קריטי לחלוקת הנתונים ב-GroupKFold ולמניעת זליגת מידע (Speaker Leakage) בין קבוצות האימון, האימות והבדיקה	`speaker_id`
תווית המחלקה (המבטא) לסיווג: `chinese`, `indian`, `nigerian`, `usa`	`accent`
התמלול של קטע הדיבור, המשמש לחישוב המאפיינים הפונטיים.	`text`

2. טבלת המאפיינים המרוכזת (`master_extracted_features_<mode>.csv`)

הטבלה מכילה 4800 שורות ומעל 70 עמודות . נוצרת על ידי `extract_features.py` באמצעות הפונקציות ב-`extract_features_to_files.py` בתיקיית /features. היא משמשת מקור הנתונים הראשי למודלי ה-Machine Learning, וכן מספקת את הוקטור הפונטי שמשתלבי עם הספקטוגרמה במודל המולטי-מודאלי. המבנה שלה מתחלק למאפיינים אקוסטיים- פיזיולוגיים (למשל `mean_centroid`, `mean_rolloff`) , מאפיינים דינמיים למשל (`jitter`, `shimmer`) ומאפיינים פונטיים (`phn_voiced`, `phn_fricative`) מהם נוצר הוקטור הפונטי כמפורט בדו"ח הפרויקט.

3. טנזורי ספקטרוגרמה (Spectrogram Tensors)

הספקטוגרמה של אודיו נוצרת על ידי `create_spectogram.py` ונשמרת כקובץ PyTorch Tensor (`.pt`).
באמצעות `torchaudio`. בתהליך זה קובץ האודיו נחתך לאורך קבוע של 4 שניות (ב-16 kHz) ומומר לגרף תדר-זמן בגודל קבוע של 126×128 (128 תדרי Mel על פני 126 חלונות זמן). הספקטרוגרמות מחושבות בסקאלה לוגריתמית (Log-Mel dB) ועוברות נרמול Z-score כדי להכין אותן כקלט לרשת ה-CNN.
שמירת הספקטרוגרמות בפורמט pt. מאפשרת לשמור על דיוק הערכים האקוסטיים ללא אובדן מידע בהמרה לתמונה .בנוסף שימוש בפורמט זה מצמצם את זמן העיבוד והאימון.

4. וקטור פונטי

וקטור של 5 מספרים המייצגים את שכיחות צלילי ה IPA-בדיבור (כגון עיצורים קוליים, פיצוציים, תנועות ארוכות וכו').
ברשת ה CNN-המולטי-מודאלית, הווקטור מוזרק במקביל לספקטרוגרמה, משולב עם הייצוג האקוסטי של הרשת דרך מנגנון Gated Residual Fusion המבוסס על פונקציית האקטיבציה Sigmoid .
במודל ה־ CNN הדו־ענפי, הווקטור הפונטי משולב עם המידע מהספקטרוגרמה. בשל מגבלות חישוב, הווקטור אינו שומר את סדר הפונמות לפי מיקומן בזמן, ולכן אינו מאפשר התאמה ישירה בינן לבין אזורי הספקטרוגרמה. עם זאת מאחר שמדובר בקטעי דיבור קצרים של עד ארבע שניות, הוא עשוי לתרום מידע פונטי שימושי בתהליך הסיווג, ללא צורך בהתאמה מדויקת של כל פונמה.

קלט ופלט למערכת

<u>קלט</u>: המשתמש מעלה קובץ אודיו חדש ,שעובר את אותו תהליך עיבוד מקדים וחילוץ פיצ'רים .לאחר הנרמול , הווקטור פיצ'רים של אותו אודיו מוזן למסווג הסופ שהשיג את התוצאות הטובות ביותר.

להלן תיאור קובץ אודיו במסלול Machine Learning:

```
audio

-> normalization

-> extract_features.py

-> master_extracted_features_<mode>.csv

-> main_machine_learning.py
```

להלן תיאור קובץ אודיו במסלול CNN:

```
audio

-> create_spectogram.py

-> spectograms_logmel_<mode>/

-> main_multimodal_cnn.py / main_cnn.py
```

<u>הפלט</u>: התוכנה מציגה את המבטא שחזה המסווג ,וגם את אחוז השייכות של האודיו לכל אחת מארבע קבוצות המבטא , לדוגמה:

```
Results breakdown:
   ├─ Chinese   : 72.49%
   ├─ Indian    : 8.88%
   ├─ Nigerian  : 1.30%
   ├─ Usa       : 17.33%
============================================================
your accent is : CHINESE
============================================================
```